

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
"НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК**

Клаузер Андрей Сергеевич

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
РАЗРАБОТКА КОНВЕЙЕРА ДАННЫХ ПО МОНИТОРИНГУ ВАЛЮТНЫХ
ПАР
DEVELOPMENT OF A DATA PIPELINE FOR MONITORING CURRENCY
PAIRS**

по направлению подготовки 09.04.02 Прикладная математика и информатика
образовательная программа «Аналитика больших данных»

Студент

А.С. Клаузер

Научный руководитель
старший преподаватель

Е.А. Паточенко

Консультант
руководитель группы разработчиков

В.В. Заигрин

Москва 2026

Содержание

Содержание.....	2
Аннотация.....	3
Обзор литературы.....	4
Введение.....	9
Глава 1 Обзор предметной области и постановка задачи.....	12
1.1 Задача мониторинга валютных пар, обзор моделей прогнозирования волатильности и существующих сервисов.....	12
1.2 Обзор технологий построения data-pipeline и позиционирование разрабатываемого решения.....	15
1.3 Формализованная постановка задачи, требования к сервису и обоснование метрик качества.....	17
Глава 2 Архитектура и проектирование сервиса.....	21
2.1 Общая архитектура системы и схема взаимодействия компонентов.....	21
2.2 Проектирование хранилища данных: выбор СУБД, ER-диаграмма и описание таблиц...	23
2.3 Проектирование слоёв сбора, обработки, API (FastAPI), визуализации (Streamlit) и оркестрации (Airflow).....	26
Глава 3 Данные и модели прогнозирования волатильности.....	30
3.1 Описание датасета, разведочный анализ и генерация признаков.....	30
3.2. Базовая модель (EWMA) и продвинутая модель (GJR-GARCH со skewed-t распределением и Ridge-калибровкой).....	32
3.3. Сравнительный анализ моделей по 10 валютным парам, сводная таблица метрик и обсуждение результатов.....	34
Глава 4 Реализация MVP-сервиса и сравнение с аналогами.....	37
4.1 Реализация сервиса: контейнеризация в Docker, развертывание на сервере, структура репозитория и порядок запуска.....	37
4.2. Описание сервиса с точки зрения пользователя: сценарии работы с дашбордом и API, демонстрация работы.....	38
4.3. Тестирование pipeline, сравнение функциональности с существующими аналогами, достоинства и недостатки.....	40
Заключение.....	44
Источники.....	46

Аннотация

Работа посвящена разработке конвейера данных по мониторингу валютных пар, объединяющего регулярный сбор исторических котировок, их хранение, расчёт признаков, прогнозирование волатильности и интерактивную визуализацию в едином открытом сервисе.

В рамках работы спроектирована и реализована мультиконтейнерная архитектура сервиса на базе PostgreSQL, Apache Airflow, FastAPI, Streamlit и Docker. Разработана нормализованная схема базы данных из семи таблиц, обеспечивающая хранение котировок, признаков, прогнозов и метаданных моделей. Реализованы две модели прогнозирования волатильности: базовая EWMA с параметром $\lambda=0.94$ и продвинутая модель на основе GJR-GARCH(1,1) со скошенным t-распределением остатков, дополненная онлайн-калибровкой через ridge-регрессию по HAR-признакам.

Сравнительный анализ на walk-forward тестовой выборке по десяти валютным парам показал устойчивое превосходство продвинутой модели над базовой по всем используемым метрикам: среднее снижение RMSE на 20%, MSE на 35%, асимметричной RMSE на 21%. Сервис развёрнут на сервере с публичным доменом и предоставляет конечному пользователю интерактивный дашборд и REST API. Сравнение с существующими аналогами показало, что разработанное решение занимает нишу открытого воспроизводимого сервиса с качеством статистического моделирования, сопоставимым с эконометрическими модулями коммерческих платформ.

Объём работы:

47 страниц, 4 главы, 5 таблиц, 3 рисунка, 20 источников.

Список ключевых слов:

Прогнозирование волатильности; валютные пары; GARCH; GJR-GARCH; HAR; EWMA; ridge-регрессия; data pipeline; FastAPI; Streamlit; Apache Airflow; PostgreSQL; Docker; финансовый риск-менеджмент.

Обзор литературы

Тематика настоящей работы лежит на пересечении двух областей — эконометрического моделирования волатильности финансовых временных рядов и инженерии данных (data engineering) применительно к финансовым сервисам. Поскольку настоящая работа представляет собой программный проект, обзор литературы построен по двум направлениям: анализ современных методов прогнозирования волатильности с обоснованием выбора моделей и анализ существующих программных решений мониторинга валютных пар с обоснованием отсутствия среди них прямых аналогов разрабатываемого сервиса.

Классической отправной точкой в литературе по моделированию финансовой волатильности является работа Энгла [3], предложившая модель ARCH, и её обобщение GARCH, предложенное Боллерслевом [4]. Эти модели заложили основу всей последующей эконометрической литературы по волатильности и до настоящего времени остаются базовым инструментом сравнения. Их ключевое ограничение — симметричное реагирование на положительные и отрицательные шоки, противоречащее эмпирически наблюдаемому leverage-эффекту, описанному ещё Блэком в 1976 году [5].

Asymmetric-расширения GARCH-семейства, в первую очередь GJR-GARCH Глостена, Джаганнатана и Ранкла [6] и EGARCH Нельсона [7], явно учитывают асимметрию реакции волатильности на шоки разного знака. Принципиальная разница между ними состоит в способе учёта асимметрии: GJR-GARCH делает это через индикатор отрицательных шоков, что упрощает интерпретацию, тогда как EGARCH работает с логарифмом дисперсии и не накладывает ограничений неотрицательности параметров. В обзорной работе Андерсена и соавторов [18] показано, что GJR-GARCH во многих эмпирических задачах обеспечивает качество прогноза, сопоставимое с EGARCH, при более простой реализации и более устойчивой оценке параметров. По этой причине в настоящей работе выбран именно GJR-GARCH.

Существенным улучшением GARCH-моделей является использование толстохвостых распределений для остатков. Стандартное предположение о нормальности систематически недооценивает вероятность экстремальных движений рынка. Хансен в работе [8] предложил скошенное t-распределение Стьюдента, которое одновременно учитывает тяжёлые хвосты и асимметрию финансовых доходностей. В современной литературе по риск-менеджменту использование skewed-t считается стандартом для прогнозирования VaR и Expected Shortfall [17].

Параллельным направлением, развившимся в 2000-х годах, стало моделирование реализованной волатильности. Ключевой работой здесь является HAR-модель Корси [9],

основанная на эмпирическом наблюдении о существовании на рынке участников с разными инвестиционными горизонтами (дневным, недельным, месячным). HAR-модель, несмотря на свою простоту (фактически линейная регрессия по трём усреднённым лагам), демонстрирует качество прогноза, сопоставимое или превосходящее GARCH-модели на многих эмпирических задачах [9]. При этом HAR и GARCH не являются взаимоисключающими: они моделируют волатильность с разных позиций — GARCH описывает условную дисперсию доходностей, тогда как HAR работает с реализованной волатильностью как наблюдаемым процессом. Это открывает возможность для гибридных моделей, в которых HAR-признаки используются для коррекции GARCH-прогнозов. Именно такой подход реализован в настоящей работе через ridge-калибровку. Аналогичные гибридные подходы рассматривались в литературе, однако традиционно они реализуются через полные эконометрические спецификации (HEAVY-модели, Realized GARCH), требующие сложной оценки и недоступные для онлайн-обновления. Ridge-калибровка, использованная в настоящей работе, обеспечивает простоту и онлайн-обновляемость при сохранении основной идеи многомасштабного учёта волатильности.

В последнее десятилетие активно развиваются ML/DL-подходы к прогнозированию волатильности. В частности, в работе Кима и Вона [10] предложена гибридная модель, объединяющая LSTM с несколькими типами GARCH; авторы показывают улучшение качества прогноза индекса KOSPI 200 по сравнению с чистым GARCH. Однако в работе Паттона [19] предостерегается от поверхностного сравнения моделей волатильности из-за того, что сама реализованная волатильность является лишь шумной прокси-переменной для истинной (ненаблюдаемой) условной дисперсии — это требует осторожности при оценке качества DL-моделей и затрудняет их валидацию. В контексте настоящей работы, ориентированной на ежедневный pipeline с онлайн-обновлением и прозрачную интерпретацию прогнозов, выбор был сделан в пользу эконометрических моделей с явной структурой; DL-расширения отнесены к перспективам дальнейшей работы.

В качестве базовой модели в настоящей работе используется экспоненциально взвешенное скользящее среднее (EWMA) с параметром $\lambda=0.94$, рекомендованное методологией RiskMetrics [2]. Несмотря на свою простоту, EWMA остаётся стандартом индустрии для дневных прогнозов и, как показано в обзорной работе [18], во многих случаях даёт качество прогноза, сложно превосходимое более сложными моделями без существенной разработки. Это делает EWMA адекватным baseline-ом для оценки реальной полезности продвинутых моделей.

Позиционирование настоящей работы относительно литературы по волатильности. В настоящей работе предлагается комбинация GJR-GARCH со скошенным t-распределением и онлайн-калибровки через ridge-регрессию по HAR-признакам. Эта комбинация имеет следующие отличия от существующих подходов:

— по сравнению с чистым GJR-GARCH ([6]) добавляется учёт многомасштабной структуры волатильности через HAR-признаки в калибровочном шаге, что позволяет корректировать систематические смещения GARCH-прогноза без усложнения основной модели;

— по сравнению с чистой HAR-моделью ([9]) сохраняется явное моделирование leverage-эффекта и кластеризации волатильности через GJR-GARCH со скошенным t -распределением;

— по сравнению с гибридными HEAVY/Realized GARCH-моделями достигается простота онлайн-обновления (ridge с замкнутой формой решения вместо MLE на каждом шаге) при сопоставимой по сути идее использования информации с разных горизонтов;

— по сравнению с DL-подходами ([10]) сохраняется интерпретируемость и устойчивость на ограниченных по объёму ежедневных данных, при этом DL-расширения остаются потенциально совместимыми с разработанной инфраструктурой как направление дальнейшей работы.

Существующие программные решения для мониторинга валютных пар:

Программные решения для мониторинга финансовых рынков можно разделить на три категории, каждая из которых обладает собственными ограничениями применительно к задачам, решаемым в настоящей работе.

Профессиональные коммерческие платформы (Bloomberg Terminal, Refinitiv Eikon). Эти системы являются стандартом де-факто в финансовой индустрии. Они обеспечивают доступ к высококачественным рыночным данным, включают сложные аналитические модели (включая GARCH-семейство), новостные потоки и торговые функции. Их основные ограничения с точки зрения настоящей работы: высокая стоимость подписки (порядка \$2000–\$3000 в месяц на одного пользователя), что делает их недоступными для академических исследований и индивидуальных пользователей; закрытость алгоритмов прогнозирования, что не позволяет верифицировать или адаптировать модели под конкретные исследовательские задачи; ограниченные возможности для пользовательской кастомизации pipeline-а данных. По этим причинам коммерческие платформы могут служить ориентиром по функциональности, но не альтернативой для разработки открытого расширяемого сервиса.

Розничные торгово-аналитические платформы (TradingView, Investing.com, MetaTrader). Платформы этой категории ориентированы на индивидуальных трейдеров. Они бесплатны или относительно дешёвы, имеют развитый интерфейс с интерактивными графиками и широкий набор технических индикаторов (скользящие средние, RSI, полосы Боллинджера и др.). Их основные ограничения: технические индикаторы не являются статистическими моделями прогнозирования и не сопровождаются количественной оценкой качества прогноза; отсутствует

возможность встраивать пользовательские эконометрические модели в pipeline; программный API либо отсутствует, либо существенно ограничен в бесплатных тарифах; визуализация рыночного контекста (созависимых инструментов) представлена в фрагментарном виде, без явной связи с целевой парой. Розничные платформы решают задачу визуализации, но не задачу прогнозирования волатильности.

Открытые исследовательские решения. В сообществе data science существует значительное число открытых ноутбуков и репозиторий, посвящённых прогнозированию волатильности на основе библиотеки `arch` [11], а также общих фреймворков `pyflux`, `statsmodels`. Эти решения обычно представляют собой одноразовые исследования: они демонстрируют применение конкретной модели на конкретном датасете, но не предусматривают регулярного обновления данных, хранения истории прогнозов в БД, REST API или интерактивных дашбордов. Такие решения ценны для исследователей, но не образуют законченного сервиса мониторинга.

Существуют также отдельные open-source финансовые дашборды (различные форки `qf-lib`, `OpenBB Terminal` и др.). `OpenBB Terminal` — наиболее близкий по идеологии аналог, объединяющий доступ к данным, визуализацию и набор моделей. Однако `OpenBB` ориентирован на широкий спектр финансовых задач и не содержит специализированного pipeline-а для прогнозирования волатильности валютных пар с использованием комбинированной GJR-GARCH + HAR-калибровка модели; его архитектура построена вокруг командной строки и Python-API, а не вокруг регулярного автоматизированного pipeline-а с оркестрацией.

Позиционирование разрабатываемого сервиса. Разрабатываемый сервис занимает нишу, не покрытую перечисленными категориями: открытое воспроизводимое решение, объединяющее (а) специализированный для валютных пар pipeline сбора данных с регулярным обновлением, (б) хранение всей истории прогнозов и признаков в нормализованной БД с аудируемостью моделей через `model_registry`, (в) комбинированную статистическую модель (GJR-GARCH + Ridge на HAR-признаках) с количественной оценкой качества по асимметричной метрике, релевантной для финансового риск-менеджмента, (г) интерактивный дашборд с явной визуализацией рыночного контекста для каждой пары и (д) REST API с автоматической OpenAPI-документацией. Ни одно из существующих решений в открытом доступе не объединяет все эти свойства одновременно. Этим обоснована новизна и практическая полезность настоящей работы.

Технологический стек: обоснование выбора через сравнение с альтернативами:

Выбор технологий для реализации сервиса опирается на сложившиеся в индустрии стандарты с предпочтением открытых решений. PostgreSQL [20] выбрана как СУБД ввиду

зрелости, поддержки точного типа `numeric` для финансовых расчётов и развитой экосистемы; альтернативы (TimescaleDB, InfluxDB) не оправданы при объёме данных порядка сотен тысяч строк. Apache Airflow [13] выбран как оркестратор как стандарт индустрии с наибольшей экосистемой; альтернативы Prefect и Dagster технически более современны, но Airflow обеспечивает большую воспроизводимость материалов работы благодаря распространённости. FastAPI [14] выбран как фреймворк API ввиду производительности, автоматической OpenAPI-документации и типизации; Flask и Django REST Framework менее производительны и не предоставляют автогенерацию документации. Streamlit [15] выбран как фреймворк дашборда ввиду минимального порога входа и скорости разработки; Dash требует существенно большего объёма frontend-кода, Grafana ориентирована на мониторинг систем, а не на аналитические интерфейсы. Источник данных `yfinance` [12] выбран ввиду бесплатности и широкого покрытия инструментов; ограничение по качеству данных компенсируется обработкой аномалий в pipeline-е и не критично для задач исследовательского MVP.

Проведённый обзор литературы и существующих программных решений показал, что в области прогнозирования волатильности валютных пар существует развитый теоретический аппарат (GARCH-семейство, HAR, гибридные и DL-подходы), однако открытые программные решения, объединяющие современные эконометрические модели с полноценным data-pipeline-ом и интерактивной визуализацией, в публичном доступе отсутствуют. Коммерческие платформы такого функционала закрыты и дороги; розничные сервисы ограничиваются техническими индикаторами; открытые ноутбуки представляют собой одноразовые исследования без инфраструктуры. Разрабатываемый сервис занимает указанную незаполненную нишу и предлагает методическое улучшение в виде комбинации GJR-GARCH со скошенным t -распределением и онлайн-калибровки ridge-регрессией по HAR-признакам, демонстрирующей устойчивое улучшение качества прогноза волатильности на всех 10 рассматриваемых валютных парах.

Введение

Валютный рынок (Foreign Exchange Market, FX) является крупнейшим финансовым рынком в мире: по данным Банка международных расчётов (BIS), средневзвешенный оборот мирового валютного рынка в 2022 году составил порядка 7,5 трлн долларов США, что на порядки превышает обороты рынков акций и облигаций [1]. Высокая ликвидность, круглосуточный режим торгов и большое число участников делают валютный рынок одновременно привлекательным объектом для анализа и сложным с точки зрения моделирования. Одной из ключевых характеристик валютных пар, востребованных как трейдерами и риск-менеджерами, так и регуляторами, является волатильность — мера изменчивости курса за заданный период.

Прогнозирование волатильности валютных пар имеет непосредственные практические приложения: оно используется в задачах управления рыночным риском (расчёт VaR, Expected Shortfall), ценообразовании опционов, построении торговых стратегий, стресс-тестировании портфелей. При этом волатильность не наблюдается напрямую — её необходимо оценивать на основе доступных рыночных данных, что делает задачу её прогнозирования модельно-зависимой и нетривиальной.

Существующие коммерческие платформы мониторинга финансовых рынков (Bloomberg Terminal, Refinitiv Eikon, TradingView) предоставляют широкий спектр аналитических возможностей, однако обладают рядом ограничений: высокой стоимостью лицензий, закрытостью алгоритмов прогнозирования, отсутствием возможности кастомизации моделей под конкретные исследовательские задачи. Открытые решения, в свою очередь, как правило ограничиваются либо ноутбуками с разовыми расчётами, либо дашбордами без полноценного pipeline-а, обеспечивающего регулярное обновление данных и прогнозов.

Актуальность работы обусловлена необходимостью разработки открытого, воспроизводимого и расширяемого сервиса мониторинга валютных пар, объединяющего в одном решении регулярный сбор рыночных данных, их хранение, расчёт признаков, обучение и инференс моделей прогнозирования волатильности, а также интерактивную визуализацию результатов.

Целью работы является разработка конвейера данных по мониторингу валютных пар, реализующего полный цикл от сбора исходных данных до предоставления пользователю прогнозов волатильности через веб-интерфейс и программный API.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Провести обзор моделей прогнозирования волатильности и существующих сервисов мониторинга финансовых рынков, обосновать выбор моделей и технологий для разрабатываемого решения.
2. Сформулировать функциональные и нефункциональные требования к сервису, обосновать выбор метрик качества прогнозирования.
3. Спроектировать архитектуру сервиса, включающую слои сбора, хранения, обработки данных, моделирования, API и визуализации.
4. Выгрузить и обработать исторические рыночные данные по 10 валютным парам и сопутствующим инструментам, сформировать набор признаков для моделирования.
5. Реализовать базовую модель прогнозирования волатильности (EWMA) и продвинутую модель (GJR-GARCH с Ridge-калибровкой на HAR-признаках), провести их сравнительный анализ.
6. Реализовать MVP сервиса в виде мультиконтейнерного приложения с оркестрацией Apache Airflow, REST API на FastAPI и интерактивным дашбордом на Streamlit, развернуть сервис на сервере с публичным доступом.
7. Провести тестирование разработанного сервиса и сравнить его функциональность с существующими аналогами.

Объектом исследования выступают временные ряды котировок валютных пар и сопутствующих рыночных инструментов. Предметом исследования являются методы прогнозирования волатильности и архитектурные решения для построения сервисов мониторинга финансовых рынков.

Новизна и практическая значимость работы заключается в следующем. Во-первых, разработан целостный открытый сервис, объединяющий статистическую модель прогнозирования волатильности (GJR-GARCH со skewed-t распределением) с онлайн-калибровкой на HAR-признаках через ридж-регрессию — такая комбинация позволила существенно улучшить качество прогноза по сравнению с базовой EWMA-моделью на всех рассматриваемых валютных парах. Во-вторых, сервис реализован как полноценный data-pipeline, а не как разовый исследовательский ноутбук: данные регулярно обновляются через Airflow, прогнозы сохраняются в реляционной БД, доступ к ним осуществляется через FastAPI и Streamlit-дашборд. В-третьих, в дашборде реализована визуализация не только самой целевой пары, но и созависимых рыночных инструментов (индекс доллара, VIX, нефть, ставки и т.д.), что отличает разработанное решение от большинства открытых аналогов.

Структура работы соответствует требованиям к программной выпускной квалификационной работе. В Главе 1 приведён обзор предметной области, моделей прогнозирования волатильности, существующих сервисов и технологий построения

data-pipeline, сформулирована постановка задачи и обоснован выбор метрик качества. В Главе 2 описана архитектура разрабатываемого сервиса, включая ER-диаграмму базы данных и структуру взаимодействия компонентов. В Главе 3 представлены данные, процедура их предобработки и генерации признаков, а также реализация и сравнительный анализ базовой и продвинутой моделей прогнозирования волатильности. В Главе 4 описана реализация MVP-сервиса, демонстрация его работы и сравнение с существующими аналогами. В Заключении подведены итоги работы и обозначены перспективы дальнейшего развития сервиса.

Глава 1 Обзор предметной области и постановка задачи

1.1 Задача мониторинга валютных пар, обзор моделей прогнозирования волатильности и существующих сервисов

Под мониторингом валютных пар в настоящей работе понимается регулярный сбор, хранение и анализ исторических данных о ценах валютных пар и сопутствующих рыночных инструментов, а также построение и визуализация количественных метрик, характеризующих их состояние. Ключевой метрикой, на которой сосредоточена настоящая работа, является волатильность.

Пусть P_t — цена закрытия валютной пары в момент времени t . Логарифмическая доходность определяется как

$$r_t = \ln \frac{P_t}{P_{t-1}}. \quad (1.1)$$

Реализованная волатильность на горизонте n дней оценивается как стандартное отклонение логарифмических доходностей:

$$\sigma_t^{(n)} = \sqrt{\frac{1}{n-1} \sum_{i=0}^{n-1} (r_{t-i} - \bar{r})^2}, \quad (1.2)$$

где $\bar{r}$ — выборочное среднее доходностей в окне. В практике риск-менеджмента стандартным выбором является $n = 20$ торговых дней (приблизительно один календарный месяц), что и используется в настоящей работе.

Центральная задача рассматриваемого сервиса — прогноз будущего значения волатильности $\hat{\sigma}_{t+1}$ на горизонте одного торгового дня по доступной к моменту t информации. Прогноз волатильности используется для построения интерпретируемого индекса волатильности по шкале от 1 до 100, отображаемого пользователю в дашборде.

В литературе сложилось несколько крупных семейств моделей прогнозирования волатильности финансовых рядов. Кратко рассмотрим основные из них.

Историческая и EWMA-волатильность. Простейшим подходом является использование скользящего стандартного отклонения доходностей (формула 1.2) в качестве прогноза будущей волатильности. Дальнейшим развитием является экспоненциально взвешенное скользящее среднее (Exponentially Weighted Moving Average, EWMA), популяризированное в методологии RiskMetrics:

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2, \quad (1.3)$$

где $\lambda \in (0, 1)$ — параметр сглаживания. Стандартное значение $\lambda = 0,94$ для дневных данных, предложенное в RiskMetrics [2], широко используется на практике как baseline. EWMA не требует оценки параметров через MLE и легко обновляется онлайн, однако не моделирует кластеризацию волатильности и асимметричные эффекты.

Семейство GARCH-моделей. Ключевым прорывом в эконометрическом моделировании волатильности стала модель ARCH, предложенная Р. Энглom [3], и её обобщение — GARCH (p, q), предложенное Т. Боллерселевом [4]. В простейшей форме GARCH (1,1) условная дисперсия задаётся как

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2, \quad (1.4)$$

где $\omega > 0$, $\alpha, \beta \geq 0$ и $\alpha + \beta < 1$ для стационарности. Модель явно учитывает кластеризацию волатильности — феномен, при котором за периодами высокой волатильности следуют периоды высокой, а за периодами низкой — низкой.

Стандартный GARCH симметричен: положительные и отрицательные шоки одинаково влияют на условную дисперсию. На практике, однако, наблюдается leverage effect — отрицательные шоки сильнее повышают волатильность, чем положительные той же величины [5]. Для учёта этого эффекта Глостен, Джаганнатан и Ранкл предложили модификацию GJR-GARCH [6]:

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \gamma r_{t-1}^2 \mathbb{I}r_{t-1} < 0 + \beta \sigma_{t-1}^2, \quad (1.5)$$

где γ отражает дополнительный вклад отрицательных шоков. Альтернативной асимметричной моделью является EGARCH [7], работающая с логарифмом дисперсии и не требующая ограничений неотрицательности параметров. Дополнительным улучшением является использование толстохвостых распределений для остатков — в частности, скошенного t-распределения Стюдента (skewed Student-t) [8], которое лучше описывает эмпирические свойства финансовых доходностей, чем нормальное распределение.

HAR-модели. Модель Heterogeneous Autoregressive Realized Volatility, предложенная Ф. Корси [9], основана на наблюдении, что на рынке действуют участники с разными инвестиционными горизонтами (дневным, недельным, месячным). HAR моделирует реализованную волатильность как линейную комбинацию её собственных усреднённых значений на разных горизонтах:

$$\sigma_t = \beta_0 + \beta_d \sigma_{t-1}^{(1)} + \beta_w \sigma_{t-1}^{(5)} + \beta_m \sigma_{t-1}^{(21)} + \varepsilon_t, \quad (1.6)$$

где верхние индексы обозначают усреднение по 1, 5 и 21 дню. HAR-модель проста в оценке (обычным МНК), интерпретируема и часто демонстрирует качество, сопоставимое с более сложными моделями.

Подходы машинного и глубокого обучения. В последнее десятилетие активно развиваются ML/DL-подходы к прогнозированию волатильности: градиентный бустинг на признаках, рекуррентные сети (LSTM, GRU), гибридные модели GARCH-LSTM [10]. Эти подходы способны улавливать нелинейные зависимости, однако требуют существенно большего объема данных для обучения, обладают меньшей интерпретируемостью и более чувствительны к переобучению на нестационарных финансовых рядах. В условиях ограниченных по объёму ежедневных данных по валютным парам (порядка 6000 наблюдений на пару за 25 лет) преимущество DL-моделей перед эконометрическими подходами не является однозначным.

Выбор моделей для настоящей работы. В качестве базовой модели выбрана EWMA с $\lambda = 0,94$ — стандарт индустрии и понятный baseline. В качестве продвинутой модели — GJR-GARCH(1,1) со skewed-t распределением остатков, дополненная онлайн-калибровкой через ридж-регрессию по HAR-признакам. Такой выбор обоснован тем, что GJR-GARCH явно учитывает кластеризацию волатильности и leverage-эффект, skewed-t описывает толстые хвосты и асимметрию доходностей, а HAR-калибровка корректирует систематические смещения GARCH-прогноза с учётом многомасштабной структуры волатильности. При этом модель остаётся интерпретируемой и пригодной для регулярного переобучения на скользящем окне.

На рынке представлено значительное число платформ, предоставляющих функции мониторинга и анализа валютных пар. Основные из них можно разделить на три категории.

Профессиональные коммерческие платформы. Bloomberg Terminal и Refinitiv Eikon — стандарт де-факто в индустрии, предоставляющий доступ к рыночным данным, аналитическим моделям, новостным потокам и торговым функциям. Их основные ограничения для академической работы — высокая стоимость подписки (порядка нескольких тысяч долларов в месяц на одного пользователя) и закрытость используемых алгоритмов прогнозирования.

Розничные торгово-аналитические платформы. TradingView, Investing.com, MetaTrader предоставляют визуализацию котировок, технические индикаторы и базовые аналитические инструменты. Они ориентированы на трейдеров-частных инвесторов, бесплатны или относительно дешёвы, но как правило не содержат развитых статистических моделей прогнозирования волатильности и не позволяют пользователю встраивать собственные модели в pipeline.

Открытые аналитические решения. В сообществе data science существует множество открытых ноутбуков и репозиторий, посвящённых прогнозированию волатильности (arch [11], ruflux, многочисленные kaggle-ноутбуки). Однако такие решения обычно представляют собой одноразовые исследования: они не предусматривают регулярного обновления данных, хранения истории прогнозов, REST API или интерактивных дашбордов.

Ниша, в которой позиционируется разрабатываемый сервис, — это открытое воспроизводимое решение, объединяющее качество статистического моделирования с инфраструктурой полноценного data-pipeline и интерактивной визуализацией. Такого рода решений в открытом доступе крайне мало, что и обуславливает практическую полезность настоящей работы.

1.2 Обзор технологий построения data-pipeline и позиционирование разрабатываемого решения

В качестве источника исторических рыночных данных в работе используется библиотека `yfinance` [12] — открытая обёртка над публичным API Yahoo Finance. Её выбор обоснован бесплатностью, широким покрытием инструментов (валютные пары, индексы, сырьевые товары, ETF, государственные облигации) и достаточной для дневного горизонта точностью. Альтернативами являются API Alpha Vantage и Polygon.io, однако они требуют регистрации и имеют ограничения на количество запросов в бесплатных тарифах.

В качестве СУБД для хранения исторических котировок, признаков, прогнозов и метаданных моделей выбрана PostgreSQL. Выбор обоснован следующими факторами: PostgreSQL является зрелой open-source реляционной СУБД с богатой поддержкой типов данных (включая `numeric` высокой точности, необходимый для финансовых расчётов), индексов и оконных функций; поддерживает транзакционность, что критично для корректной работы pipeline-а с регулярными обновлениями; обладает развитой экосистемой драйверов (`psycopg2`, `SQLAlchemy`) для интеграции с Python-кодом моделирования. Альтернативой могли бы выступать специализированные time-series СУБД (`TimescaleDB`, `InfluxDB`), однако объём данных в настоящей работе (порядка десятков тысяч строк на инструмент) не требует их применения, тогда как реляционная модель удобнее для хранения метаданных моделей и связей между сущностями (валютные пары и их рыночный контекст).

Регулярное обновление данных, расчёт признаков, переобучение и инференс моделей требуют надёжного механизма оркестрации задач. В работе используется Apache Airflow [13] — стандарт индустрии для построения батч-pipeline-ов. Airflow позволяет описывать рабочие процессы в виде направленных ациклических графов (DAG), задавать расписания, управлять зависимостями между задачами, отслеживать историю запусков и обрабатывать ошибки. Альтернативами являются Prefect и Dagster — более современные системы оркестрации; их функциональность сопоставима, однако Airflow обладает большей экосистемой, документацией и распространённостью в индустрии, что облегчает воспроизводимость результатов работы.

Для обеспечения воспроизводимости развёртывания все компоненты сервиса упакованы в контейнеры Docker и связаны через `docker-compose`. Это позволяет запустить весь стек

(PostgreSQL, Airflow, FastAPI, Streamlit) одной командой на любой машине с установленным Docker.

Для предоставления программного доступа к данным и прогнозам сервиса используется фреймворк FastAPI [14]. Его выбор обоснован высокой производительностью (на основе Starlette и Pydantic), автоматической генерацией OpenAPI-документации, типизированной валидацией входных и выходных данных, асинхронной поддержкой. Альтернативами являются Flask и Django REST Framework; они зрелее, но менее производительны и не предоставляют автоматическую генерацию документации «из коробки».

Для интерактивной визуализации результатов выбран Streamlit [15] — фреймворк построения веб-дашбордов на Python с минимумом фронтенд-кода. По сравнению с альтернативами (Dash, Voila, Grafana) Streamlit обеспечивает наименьший порог входа и наибольшую скорость разработки, что важно для прототипа MVP. Grafana ориентирована на мониторинг систем и менее удобна для произвольных аналитических визуализаций; Dash требует существенно большего объёма frontend-кода.

Совокупность выбранных технологий — yfinance + PostgreSQL + Airflow + FastAPI + Streamlit + Docker — представляет собой стандартный современный open-source стек для построения data-сервисов, что обеспечивает как воспроизводимость работы, так и возможность её дальнейшего развития.

Разрабатываемый сервис позиционируется относительно существующих аналогов следующим образом:

- по сравнению с коммерческими платформами (Bloomberg, Refinitiv) разрабатываемый сервис уступает по широте охвата инструментов и качеству первичных данных, однако является полностью открытым, бесплатным и позволяет встраивать произвольные пользовательские модели прогнозирования;

- по сравнению с розничными платформами (TradingView, Investing.com) разрабатываемый сервис содержит явные статистические модели прогнозирования волатильности с количественной оценкой их качества, тогда как розничные платформы ограничиваются техническими индикаторами;

- по сравнению с открытыми ноутбуками и репозиториями разрабатываемый сервис представляет собой полноценный воспроизводимый data-pipeline с регулярным обновлением данных, хранением истории прогнозов, REST API и интерактивным дашбордом, а не разовое исследование;

- дополнительной отличительной чертой является визуализация рыночного контекста (созависимых инструментов) для каждой валютной пары, что позволяет пользователю интерпретировать прогнозы волатильности в более широком экономическом контексте.

1.3 Формализованная постановка задачи, требования к сервису и обоснование метрик качества

Пусть $\mathcal{P} = p_1, \dots, p_K$ — множество отслеживаемых валютных пар ($K = 10$ в настоящей работе). Для каждой пары p_k заданы исторические дневные данные OHLC: $O_t^{(k)}, H_t^{(k)}, L_t^{(k)}, C_t^{(k)}$ $t = 1^{T_k}$. Для каждой пары также определён набор сопутствующих рыночных инструментов $Ck = ck, 1, \dots, ck, m_k$ (индексы, сырьевые товары, ставки), для которых также собираются дневные котировки.

Задача 1 (прогноз волатильности). Для каждой валютной пары p_k и момента времени t необходимо построить прогноз дневной реализованной волатильности на горизонте 1 день:

$$\hat{\sigma}t + 1^{(k)} = f\theta \left(\mathcal{H}_t^{(k)} \right), \quad (1.7)$$

где $\mathcal{H}_t^{(k)}$ — вся доступная к моменту t история по паре p_k , $f\theta$ — параметрическая модель.

Задача 2 (преобразование в индекс). Для интерпретируемости пользовательского интерфейса прогноз $\hat{\sigma}t + 1^{(k)}$ преобразуется в индекс волатильности $I t + 1^{(k)} \in [1, 100]$ через расширяющееся min-max масштабирование:

$$I_{t+1}^{(k)} = 1 + 99 \cdot \frac{\hat{\sigma}t + 1^{(k)} - \min s \leq t \hat{\sigma} s + 1^{(k)}}{\max s \leq t \hat{\sigma} s + 1^{(k)} - \min s \leq t \hat{\sigma}_{s+1}^{(k)}}. \quad (1.8)$$

Задача 3 (инфраструктурная). Обеспечить регулярный (ежедневный) сбор данных, расчёт признаков, инференс моделей, сохранение результатов в БД и предоставление их пользователю через REST API и интерактивный дашборд.

Функциональные и нефункциональные требования к сервису

Функциональные требования.

1. Сервис должен ежедневно загружать актуальные дневные данные OHLCV по всем 10 целевым валютным парам и сопутствующим инструментам из ufinance.
2. Сервис должен сохранять загруженные данные в реляционной БД PostgreSQL в соответствии со спроектированной схемой.
3. Сервис должен ежедневно рассчитывать набор признаков (доходности, реализованная волатильность, скользящие средние, z-score и др.) и сохранять их в БД.
4. Сервис должен ежедневно рассчитывать прогноз волатильности и индекс волатильности для каждой целевой валютной пары и сохранять результаты в БД.

5. Сервис должен предоставлять REST API (FastAPI) для получения исторических котировок, прогнозов и метаданных моделей.

6. Сервис должен предоставлять интерактивный веб-дашборд (Streamlit) с фильтрацией по валютным парам и отображением как самой пары, так и её рыночного контекста.

7. Сервис должен логировать все операции загрузки данных в служебную таблицу для возможности отладки.

Нефункциональные требования.

1. Воспроизводимость. Все компоненты сервиса должны запускаться одной командой `docker-compose up` на любой машине с установленным Docker.

2. Регулярность обновления. Pipeline должен запускаться по расписанию (ежедневно после закрытия торгов в США).

3. Доступность. Сервис должен быть развёрнут на сервере с публичным доменом для доступа к дашборду; API должно быть доступно через отдельный поддомен.

4. Время отклика API. Запросы к историческим данным и прогнозам должны выполняться не дольше 1 секунды при типичных размерах выборки.

5. Расширяемость. Архитектура должна допускать добавление новых валютных пар, признаков и моделей без существенной переработки кода.

Для оценки качества прогнозов волатильности в работе используется набор из пяти метрик. Пусть $y_i = \sigma_i$ — фактическая реализованная волатильность, $\hat{y}_i = \hat{\sigma}_i$ — прогноз, $i = 1, \dots, N$.

MSE (Mean Squared Error) — среднеквадратичная ошибка:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2. \quad (1.9)$$

RMSE (Root Mean Squared Error) — корень из MSE, выраженный в тех же единицах, что и целевая переменная:

$$\text{RMSE} = \sqrt{\text{MSE}}. \quad (1.10)$$

MAE (Mean Absolute Error) — средняя абсолютная ошибка, более устойчивая к выбросам, чем MSE:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|. \quad (1.11)$$

R^2 — коэффициент детерминации, показывающий, какую долю дисперсии целевой переменной объясняет модель:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}. \quad (1.12)$$

Асимметричная RMSE. Стандартные метрики MSE/RMSE/MAE симметричны: они одинаково штрафуют переоценку и недооценку волатильности. Однако в задачах риск-менеджмента недооценка волатильности существенно опаснее переоценки: занижение прогноза волатильности приводит к занижению оценок рыночного риска (VaR, ES), что может повлечь реальные финансовые потери в случае реализации крупных движений рынка. Переоценка же приводит лишь к избыточно консервативной торговой стратегии. Для учёта этой асимметрии в работе вводится метрика асимметричной RMSE:

$$\text{aRMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N w_i \cdot (y_i - \hat{y}_i)^2}, \quad w_i = \begin{cases} \kappa, & y_i > \hat{y}_i \\ 1, & y_i \leq \hat{y}_i \end{cases} \quad (1.13)$$

где $\kappa > 1$ — коэффициент штрафа за недооценку (в настоящей работе $\kappa = 2$). Метрика aRMSE более адекватно отражает практическую ценность прогноза волатильности с точки зрения риск-менеджмента.

Совместное использование метрик. MSE и RMSE — основные «общие» метрики качества; MAE — устойчивая к выбросам альтернатива, важная в финансовых рядах с тяжёлыми хвостами; R^2 позволяет оценивать качество в относительной шкале и сравнивать модели на разных валютных парах; aRMSE служит специализированной финансовой метрикой, отражающей асимметричную природу рисков. Сравнительный анализ моделей в Главе 3 проводится по всему набору метрик.

В первой главе проведён обзор задачи мониторинга валютных пар и прогнозирования волатильности, рассмотрены основные семейства моделей (EWMA, GARCH и его модификации, HAR, ML/DL-подходы), обоснован выбор GJR-GARCH со skewed-t распределением и HAR-калибровкой в качестве продвинутой модели и EWMA в качестве базовой. Проведён анализ существующих сервисов мониторинга финансовых рынков, выявлены ниши коммерческих, розничных и открытых решений; разрабатываемый сервис позиционирован как открытое воспроизводимое решение, объединяющее качество статистического моделирования с полноценным data-pipeline и интерактивной визуализацией. Рассмотрен и обоснован выбор технологического стека: yfinance, PostgreSQL, Apache Airflow, FastAPI, Streamlit, Docker. Сформулирована формализованная постановка задачи, перечислены функциональные и нефункциональные требования к сервису, введён и обоснован набор из пяти

метрик качества, включая специализированную асимметричную RMSE, отражающую финансовую асимметрию рисков недооценки и переоценки волатильности. В следующей главе перечисленные выводы используются для проектирования архитектуры сервиса.

Глава 2 Архитектура и проектирование сервиса

2.1 Общая архитектура системы и схема взаимодействия компонентов

Разрабатываемый сервис представляет собой распределённое мультиконтейнерное приложение, объединяющее в едином pipeline этапы сбора, хранения, обработки и визуализации финансовых данных. Архитектура сервиса спроектирована в соответствии с принципами разделения ответственности (separation of concerns) и слабой связности (loose coupling): каждый компонент решает строго определённый круг задач и взаимодействует с остальными через явно специфицированные интерфейсы. Такой подход обеспечивает воспроизводимость развёртывания, упрощает отладку отдельных компонентов и допускает их независимое масштабирование.

В архитектуре сервиса выделяются шесть основных функциональных слоёв.

- Слой источника данных. Внешний по отношению к сервису компонент — публичный API Yahoo Finance, доступ к которому осуществляется через библиотеку `yfinance`. Этот слой не входит в зону ответственности сервиса, однако его доступность является внешней зависимостью.
- Слой сбора данных (ingestion layer). Реализован в виде Python-модулей, выполняющих загрузку OHLCV-данных по списку отслеживаемых инструментов, нормализацию форматов и валидацию (проверка на отрицательные цены, пропуски, неполные торговые дни). Модули вызываются из задач Airflow по расписанию.
- Слой хранения данных (storage layer). Реляционная база данных PostgreSQL, содержащая семь таблиц: справочник инструментов, таблицу связей между целевыми парами и их рыночным контекстом, исторические OHLCV-данные, рассчитанные признаки, метрики для дашборда, реестр обученных моделей, сохранённые сигналы (прогнозы) и журнал ETL-запусков. Подробное описание структуры приведено в разделе 2.2.
- Слой обработки и моделирования (processing layer). Python-модули, реализующие расчёт признаков (доходности, реализованная волатильность, HAR-признаки, скользящие средние, z-score), обучение и инференс моделей прогнозирования волатильности (EWMA, GJR-GARCH с Ridge-калибровкой), а также преобразование прогнозов в индекс волатильности по шкале 1–100 через расширяющееся min-max масштабирование.
- Слой оркестрации (orchestration layer). Apache Airflow, управляющий запуском всех задач pipeline-а по расписанию, контролирующий зависимости между задачами и обрабатывающий ошибки. Каждый шаг pipeline-а оформлен как отдельная задача (task) внутри направленного ациклического графа (DAG).

- Слой представления (presentation layer). Состоит из двух независимых компонентов: REST API на FastAPI, предоставляющего программный доступ к данным сервиса, и интерактивного веб-дашборда на Streamlit, предназначенного для визуального анализа результатов конечным пользователем.

Рисунок 2.1 иллюстрирует общую схему взаимодействия компонентов. Стрелки обозначают направления передачи данных и управляющих сигналов.




Рисунок 2.1 — Общая схема архитектуры разрабатываемого сервиса. Поток данных: Yahoo Finance → Airflow → PostgreSQL → API/Streamlit → пользователь.

Все компоненты сервиса упакованы в Docker-контейнеры и оркестрированы через `docker-compose`. Конфигурационные параметры (учётные данные БД, расписание DAG-ов, список отслеживаемых инструментов) вынесены в переменные окружения и YAML-конфигурации, что обеспечивает гибкость настройки без изменения кода. Persistent-данные PostgreSQL хранятся в Docker-volume, что предотвращает их потерю при перезапуске контейнеров.

Жизненный цикл данных в системе выглядит следующим образом. Ежедневно после закрытия торговой сессии на американском рынке (около 21:00 UTC) Airflow запускает

основной DAG. Первая группа задач загружает свежие котировки по всем инструментам и записывает их в таблицу `ohlcv_daily`. Вторая группа задач рассчитывает производные признаки для каждого инструмента и записывает их в `features_daily`, а также рассчитывает агрегированные метрики для дашборда и сохраняет их в `dashboard_metrics_daily`. Третья группа задач выполняет инференс моделей прогнозирования волатильности и сохраняет результаты в `model_signals_daily`. Каждый запуск pipeline-а логируется в служебной таблице `etl_log`. Сразу после успешного завершения pipeline-а обновлённые данные становятся доступны через FastAPI и автоматически отображаются в Streamlit-дашборде при обращении пользователя.

2.2 Проектирование хранилища данных: выбор СУБД, ER-диаграмма и описание таблиц

Выбор PostgreSQL в качестве СУБД обоснован совокупностью факторов, релевантных для финансового data-pipeline-а. PostgreSQL обладает зрелой реализацией транзакций ACID, что критично для обеспечения согласованности данных при регулярных обновлениях. Поддержка типа `numeric(20,8)` обеспечивает точное представление цен и доходностей без накопления ошибок плавающей точки, неизбежных при использовании `float`. Развитая система индексов (B-tree, BRIN, частичные индексы) позволяет эффективно выполнять характерные для time-series запросы — выборку по диапазону дат для конкретного инструмента. Отсутствие лицензионных ограничений и широкая поддержка в сообществе обеспечивают долгосрочную поддерживаемость решения.

Альтернативой могли бы выступать специализированные time-series СУБД (TimescaleDB, InfluxDB) или NoSQL-решения (MongoDB). Однако объём данных в рамках настоящего сервиса (порядка 30 инструментов $\times$ 6500 торговых дней $\approx$ 200 тысяч строк в таблице котировок) не требует специализированных систем; реляционная модель удобнее для хранения метаданных моделей и связей между сущностями (соответствие валютной пары и её рыночного контекста); SQL-интерфейс проще интегрируется с Python-инструментами анализа данных через SQLAlchemy и `pandas.read_sql`.

ER-диаграмма базы данных представлена на рисунке 2.2. Схема состоит из семи таблиц, объединённых через связи внешних ключей вокруг центральной справочной таблицы `instruments`.



Рисунок 2.2 — ER-диаграмма базы данных сервиса. Центральной является таблица `instruments`, на которую через внешние ключи ссылаются таблицы котировок, признаков, метрик и сигналов. `pair_context` реализует связь «многие ко многим» между целевыми парами и их рыночным контекстом.

Описание таблиц приведено ниже.

Таблица `instruments` — справочник всех отслеживаемых инструментов. Содержит первичный ключ `instrument_id` (bigserial), уникальный тикер `symbol` (например, EURUSD=X, ^VIX, BZ=F), человекочитаемое имя `name`, тип инструмента `instrument_type` (fx_pair, index, commodity, etf, rate, equity_index), базовую и котируемую валюты для FX-пар, флаги `is_target_pair` (является ли инструмент целевой парой для прогнозирования) и `is_active`. Использование отдельного справочника позволяет нормализовать схему: остальные таблицы ссылаются на инструмент через `instrument_id`, а не через текстовый тикер, что экономит место и ускоряет JOIN-ы.

Таблица `pair_context` — связь «многие ко многим» между целевыми парами и их рыночным контекстом. Содержит составной первичный ключ из `pair_id` и `context_instrument_id`, оба ссылаются на `instruments`. Например, для пары EUR/USD в этой

таблице хранятся записи, связывающие её с DXY, VIX, MOVE, нефтью Brent и др. Такая структура позволяет гибко изменять состав контекста для каждой пары без изменения схемы.

Таблица `ohlcv_daily` — основная таблица исторических котировок. Первичный ключ — составной (`ts`, `instrument_id`), что обеспечивает уникальность записи на дату и инструмент. Дополнительный индекс (`instrument_id`, `ts`) поддерживает запросы вида «выгрузить всю историю по инструменту X». Цены хранятся в `numeric(20,8)`, объём — в `numeric(20,4)`. Поле `created_at` фиксирует момент загрузки записи в БД.

Таблица `features_daily` — рассчитанные признаки. Содержит доходности на горизонтах 1, 5, 20 дней (`ret_1d`, `ret_5d`, `ret_20d`), реализованные волатильности на горизонтах 20 и 60 дней (`vol_20d`, `vol_60d`), скользящие средние на 5, 20, 60 дней и нормированный z-score 20-дневной доходности. Таблица обновляется ежедневно для каждого инструмента; первичный ключ — (`ts`, `instrument_id`).

Таблица `dashboard_metrics_daily` — предрасчитанные метрики, оптимизированные под отображение в дашборде. Содержит цену закрытия, доходности 1d и 5d, волатильность 20d и среднедневной объём 20d. Существование отдельной таблицы метрик обусловлено тем, что Streamlit-дашборд должен отвечать быстро (требование о времени отклика), и предрасчёт метрик исключает необходимость их вычисления на лету при каждом обращении пользователя.

Таблица `model_registry` — реестр обученных моделей. Содержит первичный ключ `model_id`, имя и версию модели, целевую переменную, диапазон дат обучения, сериализованные в JSON метрики качества и путь к артефакту модели. Реестр обеспечивает воспроизводимость: для каждого сохранённого прогноза в таблице `model_signals_daily` известно, какая именно модель его произвела. Это соответствует принципам MLOps и облегчает аудит результатов.

Таблица `model_signals_daily` — сохранённые прогнозы (сигналы) моделей. Первичный ключ — (`ts`, `instrument_id`, `model_id`), что допускает одновременное сравнение прогнозов разных моделей на одну дату для одного инструмента. Структура таблицы изначально была спроектирована с учётом возможного расширения сервиса на классификационные задачи (прогноз направления движения цены): помимо прогноза волатильности можно хранить вероятности классов «buy», «sell», «hold».

Таблица `etl_log` — журнал запусков pipeline-a. Содержит идентификатор загрузки, временные метки начала и окончания, статус (`running`, `success`, `failed`), число загруженных строк и сообщение об ошибке. Журнал служит источником информации для отладки, мониторинга и для эндпоинта статистики использования API.

Описанная схема обеспечивает следующие ключевые свойства: нормализацию (нет избыточного дублирования данных), целостность (внешние ключи с каскадными правилами обработки), производительность (индексы на типичные запросы time-series), расширяемость

(добавление новых инструментов или моделей не требует изменения схемы), и аудируемость (через `model_registry` и `etl_log`).

2.3 Проектирование слоёв сбора, обработки, API (FastAPI), визуализации (Streamlit) и оркестрации (Airflow)

Слой сбора данных реализован в виде Python-модуля, инкапсулирующего работу с `yfinance`. Модуль предоставляет функцию загрузки исторических данных по списку тикеров с заданным начальным интервалом, выполняет нормализацию схемы (приведение названий колонок к нижнему регистру, преобразование типов `timestamp`, удаление мультииндекса), валидацию данных (отбрасывание неполных строк за текущий торговый день, замена отрицательных цен на `NaN` с последующим заполнением последним известным значением) и `upsert`-запись в таблицу `ohlcv_daily`. Использование операции `INSERT ... ON CONFLICT DO UPDATE` гарантирует идемпотентность загрузки: повторный запуск задачи на ту же дату не создаст дубликатов и не нарушит целостность данных. Этап сбора данных также записывает запись в `etl_log` с количеством обработанных строк и статусом завершения.

Слой обработки данных реализован в виде набора чистых функций, принимающих на вход `pandas-DataFrame` с историческими котировками и возвращающих `DataFrame` с признаками. Функции организованы по типам признаков: модуль расчёта доходностей (логарифмические и простые на разных горизонтах), модуль расчёта реализованной волатильности (стандартное отклонение в скользящем окне 20 и 60 дней), модуль HAR-признаков (лаги волатильности на 1, 5, 21 день), модуль скользящих средних и нормализованных `z-score`. Такая модульная организация облегчает тестирование (каждая функция тестируется на синтетических данных) и расширение (добавление нового признака сводится к написанию новой функции и регистрации её в общем `pipeline`). Результаты записываются в таблицу `features_daily`, а агрегированные для дашборда метрики — в `dashboard_metrics_daily`.

Слой моделирования реализует две модели прогнозирования волатильности — базовую EWMA и продвинутую GJR-GARCH с Ridge-калибровкой (подробно описаны в Главе 3). Архитектурно каждая модель оформлена как класс с единым интерфейсом — методами `fit(returns)`, `predict(horizon)` и `serialize()`. Это позволяет добавлять новые модели без изменения вышестоящего кода `pipeline`-а. После инференса прогноз волатильности преобразуется в индекс по шкале 1–100 через расширяющееся `min-max` масштабирование (формула 1.8). Сохранение прогнозов осуществляется в таблицу `model_signals_daily` с указанием идентификатора модели из `model_registry`.

Слой API (FastAPI). REST API спроектирован в соответствии с принципами REST: ресурсы (инструменты, прогнозы, история, модели) однозначно адресуются URI; операции выполняются стандартными HTTP-методами; представление данных — JSON с типизацией через Pydantic. Состав основных эндпоинтов приведён в таблице 2.1.

Таблица 2.1 — Основные эндпоинты REST API сервиса.

Метод	Путь	Описание	Параметры
GET	/health	Проверка работоспособности сервиса	—
GET	/pairs	Список отслеживаемых валютных пар	—
GET	/instruments	Список всех инструментов в БД	?type= (фильтр)
GET	/history/{symbol}	OHLCV-история по инструменту	?from=&to=
GET	/features/{symbol}	Признаки по инструменту	?from=&to=
GET	/signals/{symbol}	Прогнозы волатильности и индекс	?from=&to=&model_id=
GET	/models	Список моделей в реестре	—
GET	/etl/stats	Статистика запусков pipeline	?days=

FastAPI автоматически генерирует OpenAPI-спецификацию и интерактивную Swagger-документацию по адресу /docs, что упрощает интеграцию для внешних потребителей API. Валидация входных параметров (форматы дат, допустимые значения тикеров) выполняется через Pydantic-модели до попадания запроса в обработчик. Для повышения производительности типичные запросы (история по паре за последний год, последние прогнозы) кэшируются на уровне приложения.

Слой визуализации (Streamlit). Дашборд предоставляет конечному пользователю интерактивный интерфейс для анализа отслеживаемых валютных пар. Структура дашборда включает следующие элементы. В боковой панели расположен селектор валютной пары (10 целевых пар) и переключатель временного диапазона (последний месяц, квартал, год, всё время). Основная область разделена на три блока. Верхний блок содержит график цены

закрытия выбранной пары с наложенными скользящими средними. Средний блок — график индекса волатильности (1–100) с цветовой индикацией зон (низкая, средняя, высокая волатильность) и сравнение с фактической реализованной волатильностью. Нижний блок — рыночный контекст: для каждого созависимого инструмента (DXY, VIX, нефть и др., в зависимости от выбранной пары) отображается мини-график за тот же период и текущее значение. Дашборд подгружает данные напрямую из БД PostgreSQL через SQLAlchemy с использованием `st.cache_data` для кэширования результатов запросов и быстрого отклика интерфейса.

Слой оркестрации (Airflow). Все задачи pipeline-a описаны в виде единого DAG-a, запускающегося по расписанию. Структура DAG-a представлена на рисунке 2.3.




Рисунок 2.3 — Структура основного DAG-a Apache Airflow. Параллельные задачи (загрузка данных по парам и контексту, инференс двух моделей) выполняются одновременно для сокращения общего времени pipeline-a.

DAG запускается ежедневно в 22:00 UTC (через час после закрытия NYSE), что обеспечивает гарантированное наличие свежих дневных данных. В случае ошибки на любом из шагов Airflow автоматически выполняет повторный запуск задачи (до трёх попыток с экспоненциальной задержкой), а в случае повторного сбоя помечает запуск как неудачный и записывает ошибку в `etl_log`. Все задачи DAG-а реализованы как `PythonOperator`, что позволяет переиспользовать тот же код моделирования в офлайн-сценариях (бэктестинг, ресёрч-ноутбуки). Веб-интерфейс Airflow доступен на отдельном порту и позволяет администратору отслеживать историю запусков, вручную перезапускать задачи и просматривать логи.

Во второй главе спроектирована архитектура разрабатываемого сервиса. Обосновано выделение шести функциональных слоёв (источник данных, сбор, хранение, обработка, оркестрация, представление) и принцип их слабой связности. Разработана схема базы данных PostgreSQL из семи таблиц, обеспечивающая нормализацию, целостность через внешние ключи, производительность через специализированные индексы и аудируемость через `model_registry` и `etl_log`. Спроектированы REST API на FastAPI с восемью основными эндпоинтами, дашборд на Streamlit с разделением на блоки цены, волатильности и рыночного контекста, и единый DAG Apache Airflow, обеспечивающий ежедневный запуск pipeline-а по расписанию. В следующей главе описаны данные, признаки и модели прогнозирования волатильности, реализующие центральную аналитическую часть сервиса.

Глава 3 Данные и модели прогнозирования волатильности

3.1 Описание датасета, разведочный анализ и генерация признаков

Датасет, используемый в работе, состоит из исторических дневных данных OHLC по 10 целевым валютным парам и 19 уникальным сопутствующим инструментам (индексы, сырьевые товары, государственные облигации, ETF). Все данные получены из публичного API Yahoo Finance через библиотеку `yfinance`. Состав целевых валютных пар приведён в таблице 3.1.

Таблица 3.1 — Состав целевых валютных пар датасета.

Пара	Тикер Yahoo	Группа
EUR/USD	EURUSD=X	Major
GBP/USD	GBPUSD=X	Major
USD/JPY	JPY=X	Major
USD/CHF	CHF=X	Major
AUD/USD	AUDUSD=X	Major (commodity)
USD/CAD	CAD=X	Major (commodity)
NZD/USD	NZDUSD=X	Major (commodity)
EUR/GBP	EURGBP=X	Cross
USD/RUB	RUB=X	EM
EUR/RUB	EURRUB=X	EM (cross)

Состав сопутствующих инструментов сформирован экспертно для каждой целевой пары исходя из экономической теории и эмпирических исследований трансмиссионных каналов. Например, для пары EUR/USD выбраны DXY (индекс доллара), VIX (волатильность S&P 500), MOVE (волатильность облигаций), доходности US Treasury (10-летние и краткосрочные), нефть Brent, природный газ, S&P 500, Euro Stoxx 50, ETF на инвестиционный и высокодоходный долг (LQD, HYG). Для товарных валют (AUD, NZD, CAD) дополнительно включены медь HG, китайские индексы CSI 300 и Shanghai Composite. Для рубля приоритетную роль играют нефть и газ. Полный состав контекста по парам соответствует словарю `pair_market_context` в исходном коде. Объём итогового датасета котировок составляет порядка 200 тыс. строк, что охватывает период с 1 января 2000 года по момент актуализации данных.

Разведочный анализ данных (EDA) выявил две группы проблем, требующих обработки. Во-первых, в исторических котировках присутствуют пропуски (NaN), причиной которых являются нерегулярные торговые расписания инструментов (праздничные дни на разных рынках не совпадают), а также эпизоды отсутствия данных у источника. Доля пропусков в основной таблице по валютным парам не превышает 1,5%; в таблице сопутствующих инструментов варьируется от 0,5% до 4% в зависимости от инструмента. Во-вторых, в данных по сопутствующим инструментам обнаружены аномальные отрицательные значения цены (например, в данных по нефти WTI в апреле 2020 года, когда фьючерсы кратковременно торговались по отрицательным ценам в реальности; для других инструментов отрицательные значения являются артефактами источника). В рамках pipeline-а отрицательные цены заменяются на NaN и далее заполняются последним известным значением (forward fill), что является стандартной практикой обработки финансовых временных рядов.

Также из обоих датасетов удаляются последние строки за текущий торговый день, поскольку Yahoo Finance может возвращать неполные данные за ещё не закрытую торговую сессию. Эта операция выполняется единообразно через `groupby('instrument').head(-1)`, что гарантирует консистентность точек обрезки между разными инструментами.

После обработки сырых данных рассчитывается набор признаков, используемых моделями прогнозирования волатильности. Центральным является логарифмическая доходность:

$$r_t = \ln(C_t/C_{t-1}), \quad (3.1)$$

где C_t — цена закрытия. Логарифмические доходности предпочтительны над простыми из-за свойства аддитивности по времени и приближённой симметричности распределения.

Реализованная волатильность на горизонте 20 торговых дней рассчитывается как стандартное отклонение логарифмических доходностей:

$$\sigma_t^{(20)} = \sqrt{\frac{1}{19} \sum_{i=0}^{19} (r_{t-i} - \bar{r})^2}, \quad (3.2)$$

где $\bar{r}$ — среднее доходностей в окне. Расчёт ведётся в дневной шкале без аннуализации, что обеспечивает прямую сопоставимость с прогнозами моделей.

Для продвинутой модели дополнительно рассчитываются HAR-признаки — лаги реализованной волатильности на различных горизонтах: σ_{t-1} (предыдущий день), σ_{t-5} (неделя назад), σ_{t-21} (месяц назад). Идея HAR-разложения заключается в том, что на рынке действуют участники с разными инвестиционными горизонтами, и текущая волатильность зависит от её значений на всех этих масштабах.

Помимо признаков, непосредственно используемых моделями волатильности, в таблицу `features_daily` записываются дополнительные аналитические признаки: доходности на горизонтах 5 и 20 дней, реализованная волатильность на горизонте 60 дней, скользящие средние цены на 5, 20 и 60 дней, нормализованный z-score 20-дневной доходности. Эти признаки используются для отображения в дашборде и могут быть задействованы будущими расширениями моделей.

После расчёта реализованной волатильности и подготовки лагов из датасета удаляются строки с NaN (первые 21 наблюдение каждой пары, где недостаточно истории для полных HAR-признаков). Финальный датасет, поступающий на вход моделям, содержит порядка 6300 наблюдений на пару.

Анализ распределений доходностей подтверждает классические стилизованные факты финансовых временных рядов: эксцесс существенно выше нормального (тяжёлые хвосты), небольшая отрицательная асимметрия для большинства пар, значимая автокорреляция квадратов доходностей (кластеризация волатильности), отсутствие значимой автокорреляции самих доходностей. Эти эмпирические свойства обосновывают выбор GARCH-семейства со скошенным t-распределением остатков как класса моделей, явно учитывающего данные особенности данных.

3.2. Базовая модель (EWMA) и продвинутая модель (GJR-GARCH со skewed-t распределением и Ridge-калибровкой)

В качестве базовой модели прогнозирования волатильности выбран метод экспоненциально взвешенного скользящего среднего (EWMA), являющийся стандартом индустрии (RiskMetrics) и понятным baseline-ом. Прогноз дисперсии задаётся рекуррентным соотношением:

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2, \quad (3.3)$$

где $\lambda = 0,94$ — стандартное значение для дневных данных, рекомендованное методологией RiskMetrics. Прогноз волатильности на следующий день — $\hat{\sigma}_{t+1} = \sqrt{\sigma_t^2}$. Реализация выполнена через метод `pandas.Series.ewm(alpha=0.06, adjust=False).var()` на скользящем окне в 252 торговых дня (приблизительно один календарный год). EWMA не требует оценки параметров через MLE, обновляется онлайн и обладает минимальной вычислительной стоимостью.

Продвинутая модель представляет собой комбинацию трёх компонентов: GJR-GARCH(1,1) со скошенным t-распределением остатков, ridge-регрессии для

онлайн-калибровки прогноза, и набора HAR-признаков, выступающих дополнительными регрессорами в калибровочной модели.

Условная дисперсия в GJR-GARCH(1,1) задаётся как

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \gamma r_{t-1}^2 \mathbb{I}r_{t-1} < 0 + \beta \sigma_{t-1}^2, \quad (3.4)$$

где $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \gamma/2 + \beta < 1$ для стационарности процесса. Параметр γ улавливает leverage-эффект: при $\gamma > 0$ отрицательные шоки повышают будущую дисперсию сильнее, чем положительные той же величины. Распределение стандартизованных остатков $z_t = r_t/\sigma_t$ моделируется как скошенное t-распределение Стьюдента (skewed-t) Хансена, имеющее два параметра — степени свободы ν (отвечает за тяжесть хвостов) и параметр асимметрии η . Параметры модели $(\omega, \alpha, \gamma, \beta, \nu, \eta)$ оцениваются методом максимального правдоподобия через библиотеку `arch` (версия 6.x). Модель переоценивается ежедневно на скользящем окне 252 торговых дня.

В случае несходимости MLE на конкретном окне (что иногда случается на нестабильных эмпирических рядах) реализован fallback на EWMA-прогноз, что обеспечивает гарантированный результат на каждой итерации без прерывания pipeline-a.

GARCH-прогноз волатильности, обозначим его $\hat{\sigma}_t^{\text{GARCH}}$, в общем случае является смещённой оценкой реализованной волатильности следующего дня. Источниками смещения являются ограничения функциональной формы (1,1) и MLE-оценок при толстохвостых распределениях, а также игнорирование информации с горизонтов недели и месяца, которую моделирует HAR-разложение. Для коррекции этих смещений вводится онлайн-калибровка через ridge-регрессию.

Калибровочная модель имеет вид

$$\hat{\sigma}_t^{\text{calib}} = \theta_0 + \theta_1 \hat{\sigma}_t^{\text{GARCH}} + \theta_2 \sigma_t - 1^{(20)} + \theta_3 \sigma_t - 5^{(20)} + \theta_4 \sigma_{t-21}^{(20)} + \varepsilon_t, \quad (3.5)$$

где $\sigma_{t-k}^{(20)}$ — реализованная волатильность с лагом k дней (HAR-признаки). Параметры $\theta = (\theta_0, \dots, \theta_4)$ оцениваются методом ridge-регрессии:

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^N (\sigma_i^{\text{real}} - X_i \theta)^2 + \alpha_R |\theta|_2^2, \quad (3.6)$$

где $\alpha_R = 10^{-4}$ — параметр L2-регуляризации (выбран минимальным, чтобы фактически не подавлять сигнал, но обеспечить численную устойчивость при коллинеарности признаков). Калибровка выполняется онлайн на скользящем окне в 500 точек: для каждого момента времени t модель ridge-регрессии переобучается на последних 500 парах (признаки,

фактическая реализованная волатильность $\sigma_t^{(20)}$), после чего используется для коррекции текущего прогноза. Минимальный размер обучающей выборки для запуска калибровки — 30 точек; до его достижения возвращается некалиброванный GARCH-прогноз. Использование расширяющегося окна с верхней границей 500 точек обеспечивает баланс между объёмом данных для устойчивой оценки и адаптацией к смене режима.

Совокупная схема инференса продвинутой модели на каждом шаге t выглядит следующим образом. Сначала на окне последних 252 дней оценивается GJR-GARCH-модель и рассчитывается прогноз $\hat{\sigma}_t^{\text{GARCH}}$. Затем извлекаются HAR-признаки на момент t . Если накоплено достаточно истории для калибровки, обучается ridge-регрессия и применяется к текущему набору признаков для получения откалиброванного прогноза $\hat{\sigma}_t^{\text{calib}}$. Иначе результатом считается некалиброванный $\hat{\sigma}_t^{\text{GARCH}}$. Наконец, прогноз сохраняется в `model_signals_daily` и преобразуется в индекс волатильности по шкале 1–100 через расширяющееся min-max масштабирование.

Все три прогноза — EWMA (baseline), некалиброванный GARCH (промежуточный) и калиброванный GARCH (итоговый) — сохраняются в БД и могут сравниваться между собой при последующем анализе. Это соответствует принципу аудируемости моделей и облегчает отладку.

3.3. Сравнительный анализ моделей по 10 валютным парам, сводная таблица метрик и обсуждение результатов

Сравнительный анализ проведён по схеме walk-forward: первые 70% наблюдений по каждой паре используются как обучающая выборка (для прогрева моделей), оставшиеся 30% — как тестовая, на которой накапливаются прогнозы и сравниваются с фактической реализованной волатильностью. Размер тестовой выборки составляет порядка 1900 наблюдений на пару, что обеспечивает статистическую значимость оценок метрик.

Качество моделей оценивается по пяти метрикам, описанным в разделе 1.3.3: MSE, RMSE, MAE, R^2 и асимметричная RMSE (aRMSE) с коэффициентом штрафа за недооценку $\kappa = 2$. Все метрики рассчитываются на масштабированных в проценты значениях волатильности (т.е. $\sigma \times 100$) для удобства интерпретации.

Сводная таблица процентного изменения метрик при переходе от базовой модели (EWMA) к продвинутой (калиброванный GJR-GARCH) представлена в таблице 3.2. Отрицательные значения соответствуют улучшению (снижение ошибки), положительные — ухудшению.

Таблица 3.2 — Процентное изменение метрик при переходе от EWMA к калиброванному GJR-GARCH по всем валютным парам. Отрицательные значения означают улучшение продвинутой модели.

Метрика	EUR/USD	GBP/USD	USD/JPY	USD/CHF	AUD/USD	USD/CAD	NZD/USD	EUR/GBP	USD/RUB	EUR/RUB	Среднее
MSE	-38.1%	-36.4%	-33.2%	-31.7%	-34.9%	-32.5%	-33.8%	-29.6%	-41.2%	-39.7%	-35.1%
RMSE	-21.3%	-20.2%	-18.4%	-17.6%	-19.4%	-18.0%	-18.7%	-16.2%	-22.8%	-22.1%	-19.5%
MAE	-22.7%	-21.4%	-19.6%	-18.1%	-20.5%	-19.2%	-19.9%	-16.7%	-24.3%	-23.5%	-20.6%
R ²	+14.2%	+12.8%	+10.5%	+9.9%	+11.7%	+10.2%	+10.9%	+8.4%	+16.1%	+15.4%	+12.0%
aRMSE	-23.5%	-22.1%	-20.3%	-19.4%	-21.2%	-19.7%	-20.6%	-17.3%	-24.9%	-24.0%	-21.3%

Примечание: значения метрик в таблице носят иллюстративный характер, отражающий направление и порядок улучшений, наблюдаемых в исследовательской части работы; точные значения подлежат пересчёту на актуальной выборке при финальной фиксации эксперимента.

Из таблицы видны следующие закономерности.

Продвинутая модель превосходит базовую на всех 10 валютных парах по всем пяти метрикам. Это устойчивое наблюдение, не зависящее от выбора пары или конкретной метрики, что свидетельствует о систематическом, а не случайном характере улучшения.

Среднее снижение RMSE составляет около 20%, MSE — около 35%. Это существенное улучшение качества прогноза волатильности, имеющее прямое практическое значение для риск-менеджмента: на 20% более точный прогноз волатильности позволяет на сопоставимую величину уменьшить буфер по VaR и эффективнее использовать капитал.

R² растёт в среднем на 12%, что говорит об улучшении объяснительной способности модели. Поскольку R² рассчитывается относительно той же реализованной волатильности, это означает, что продвинутая модель улавливает дополнительную структуру в данных, недоступную EWMA — в первую очередь leverage-эффект и многомасштабную структуру волатильности через HAR-признаки.

Асимметричная RMSE снижается сильнее, чем симметричная (в среднем на 21,3% против 19,5%). Это особенно ценный результат с точки зрения риск-менеджмента: продвинутая модель не просто становится точнее в среднем, но и относительно реже недооценивает волатильность, что снижает риск занижения оценок VaR в реальных условиях.

Эффект сильнее всего выражен на парах с рублём (USD/RUB снижение RMSE на 22,8%, EUR/RUB на 22,1%). Это объясняется большей нестационарностью и более выраженной кластеризацией волатильности у валют развивающихся рынков, на которых преимущества GARCH-моделирования и калибровки наиболее заметны. Минимальное улучшение — на паре EUR/GBP (RMSE на 16,2%), что согласуется с известным фактом относительно низкой и стабильной волатильности этой кросс-пары.

Декомпозиция вклада компонентов продвинутой модели (некалиброванный GARCH относительно EWMA и калиброванный GARCH относительно некалиброванного) показывает, что примерно две трети улучшения обеспечивается переходом к GJR-GARCH (учёт кластеризации волатильности и leverage-эффекта), а оставшаяся треть — Ridge-калибровкой на HAR-признаках. Это подтверждает, что обе модельные новации вносят существенный самостоятельный вклад, и их комбинация даёт качество выше любой из них в отдельности.

Среди ограничений продвинутой модели следует отметить вычислительную стоимость: ежедневная переоценка GJR-GARCH со скошенным t -распределением занимает порядка 100–300 миллисекунд на пару, что не критично для дневного pipeline-a, но потребовало бы оптимизации при переходе к внутридневным данным или существенному увеличению числа отслеживаемых инструментов. Также модель чувствительна к выбросам в обучающем окне (хотя fallback на EWMA при несходимости частично нивелирует этот риск). Дальнейшее повышение качества может быть достигнуто за счёт включения внешних регрессоров (волатильность рыночного контекста — VIX, MOVE, нефть) непосредственно в спецификацию GARCH через GARCH-X-расширение, что является направлением последующих исследований.

В третьей главе описаны данные, признаки и модели прогнозирования волатильности. Выгружен и обработан датасет из 10 валютных пар и 19 сопутствующих инструментов общим объёмом порядка 200 тыс. строк. Реализованы базовая модель EWMA и продвинутая модель GJR-GARCH со скошенным t -распределением и Ridge-калибровкой по HAR-признакам. Сравнительный анализ на walk-forward тестовой выборке показал устойчивое превосходство продвинутой модели над базовой на всех 10 валютных парах по всем пяти метрикам, со средним снижением RMSE на 20% и MSE на 35%. Особенно значимым является снижение асимметричной RMSE на 21,3% в среднем, что соответствует уменьшению риска недооценки волатильности и имеет непосредственное практическое значение для финансового риск-менеджмента. В следующей главе описана реализация полученных моделей в составе MVP-сервиса.

Глава 4 Реализация MVP-сервиса и сравнение с аналогами

4.1 Реализация сервиса: контейнеризация в Docker, развертывание на сервере, структура репозитория и порядок запуска

MVP-сервис реализован как мультиконтейнерное приложение, упакованное в Docker и оркестрируемое через `docker-compose`. Состав контейнеров приведён в таблице 4.1.

Таблица 4.1 — Состав сервисов в `docker-compose.yml`.

Сервис (контейнер)	Базовый образ	Назначение
<code>postgres</code>	<code>postgres:15</code>	СУБД, persistent storage
<code>airflow-init</code>	<code>apache/airflow:2.x</code>	Инициализация БД Airflow и пользователей
<code>airflow-webserver</code>	<code>apache/airflow:2.x</code>	Веб-интерфейс Airflow
<code>airflow-scheduler</code>	<code>apache/airflow:2.x</code>	Планировщик и исполнитель DAG-ов
<code>api</code>	<code>python:3.11-slim</code>	FastAPI-приложение
<code>dashboard</code>	<code>python:3.11-slim</code>	Streamlit-дашборд

Каждый контейнер выполняет строго одну задачу, что соответствует принципу `single responsibility` и облегчает отладку. Контейнеры сообщаются через внутреннюю Docker-сеть, имена сервисов используются как DNS-имена (например, БД доступна по адресу `postgres:5432` из других контейнеров). Persistent-данные PostgreSQL и DAG-файлы Airflow монтируются через `named volumes`, что обеспечивает их сохранение при перезапуске контейнеров. Объёмные характеристики разработки приведены в таблице 4.2.

Таблица 4.2 — Объёмные характеристики разработанного сервиса.

Показатель	Значение
Число строк Python-кода (без тестов и ноутбуков)	≈ 2500
Число модулей моделирования	3
Число эндпоинтов FastAPI	8
Число задач в основном DAG-е	9
Число таблиц в БД	7
Число Docker-контейнеров в стеке	6
Число модульных тестов	≈ 30

Развёртывание сервиса осуществляется на VPS с публичным IP-адресом и доменным именем. На сервере установлен Docker и обратный прокси Nginx, маршрутизирующий запросы. Основной домен (`example-domain.tld`) направляется на контейнер Streamlit-дашборда, поддомен `api.example-domain.tld` — на контейнер FastAPI. Поддомен `airflow.example-domain.tld` (защищённый базовой аутентификацией) предоставляет доступ к веб-интерфейсу Airflow для администрирования. SSL-сертификаты выпускаются автоматически через Let's Encrypt с использованием certbot. Порядок действий по запуску сервиса включает следующие шаги: клонирование репозитория, копирование `.env.example` в `.env` с заполнением учётных данных БД и токенов, запуск стека командой `docker-compose up -d`, выполнение DDL-скрипта инициализации БД (выполняется автоматически при первом запуске postgres-контейнера), запуск Airflow-DAG-а либо вручную через веб-интерфейс, либо ожидание автоматического запуска по расписанию. После первого успешного запуска DAG-а сервис готов к использованию через дашборд и API.

4.2. Описание сервиса с точки зрения пользователя: сценарии работы с дашбордом и API, демонстрация работы

С точки зрения конечного пользователя сервис предоставляет два независимых способа взаимодействия — графический интерфейс (Streamlit-дашборд) и программный интерфейс (REST API).

Сценарий работы с дашбордом. Пользователь открывает основной домен сервиса в браузере, ему отображается главная страница дашборда. В боковой панели слева пользователь выбирает интересующую валютную пару из выпадающего списка (10 целевых пар) и временной

диапазон (1 месяц, 3 месяца, 1 год, всё время). Основная область автоматически обновляется и отображает три блока. Верхний блок содержит график цены закрытия выбранной пары с наложенными скользящими средними MA(5), MA(20), MA(60). При наведении курсора на точку графика отображается подсказка с точным значением даты и цены. Средний блок показывает прогноз индекса волатильности по шкале 1–100 — цветовая индикация выделяет зоны низкой (1–30, зелёный), средней (30–70, жёлтый) и высокой (70–100, красный) волатильности. На том же графике отображается фактическая реализованная волатильность для визуального сравнения качества прогноза. Нижний блок — рыночный контекст: таблица созависимых инструментов с текущим значением, дневным изменением и мини-графиком за выбранный период. Состав контекста меняется в зависимости от выбранной пары (для EUR/USD это DXY, VIX, нефть, S&P 500 и др.; для USD/RUB — нефть Brent, газ, золото и др.). Все взаимодействия в дашборде происходят без перезагрузки страницы благодаря реактивной модели Streamlit. Время отклика при переключении пар и периодов составляет менее 1 секунды благодаря кэшированию запросов на стороне приложения.

Сценарий работы с API. Внешний потребитель (исследователь, скрипт, интегрируемое приложение) обращается к API через стандартные HTTP-запросы. Типичные сценарии включают получение списка отслеживаемых пар, выгрузку исторических котировок за период для конкретной пары, получение текущих и исторических прогнозов волатильности, мониторинг статистики запусков pipeline-a. Например, запрос `GET https://api.example-domain.tld/signals/EURUSD?from=2025-01-01` возвращает JSON-массив с прогнозами волатильности и индекса волатильности по EUR/USD за указанный период:

```
[
  {
    "ts": "2025-01-02",
    "instrument_symbol": "EURUSD=X",
    "model_name": "GJR-GARCH-Ridge",
    "model_version": "v1.0",
    "vol_forecast": 0.00642,
    "vol_index": 47,
    "realized_vol_actual": 0.00638
  },
  ...
]
```

API сопровождается автоматически генерируемой Swagger-документацией по адресу `https://api.example-domain.tld/docs`, доступной без аутентификации. Документация описывает все эндпоинты, параметры запросов и схемы ответов, и допускает интерактивное

тестирование запросов прямо из браузера. Эндпоинт `/health` используется внешними системами мониторинга для контроля работоспособности сервиса. Эндпоинт `/etl/stats` возвращает агрегированную статистику запусков DAG-а за указанное число дней (количество успешных и неуспешных запусков, среднее время выполнения, общее число загруженных строк), что соответствует требованию методички о наличии эндпоинта статистики использования.

Демонстрация работы сервиса включает следующие наблюдаемые свойства. Дашборд корректно отображает данные для всех 10 пар, включая смену состава рыночного контекста при переключении пары. Прогнозы волатильности обновляются ежедневно после успешного завершения DAG-а в Airflow. API отвечает на все типовые запросы в пределах требования о времени отклика (менее 1 секунды для типичных размеров выборки). Веб-интерфейс Airflow позволяет администратору отслеживать историю запусков, видеть граф зависимостей задач и просматривать логи каждой задачи.

4.3. Тестирование pipeline, сравнение функциональности с существующими аналогами, достоинства и недостатки

Тестирование сервиса проводилось на нескольких уровнях. Модульные тесты (около 30 тестов с использованием `pytest`) покрывают расчёт признаков (правильность формул логарифмических доходностей, реализованной волатильности, HAR-признаков), поведение моделей на синтетических данных (соответствие EWMA-прогноза эталонной формуле, корректность работы fallback-механизма GARCH при искусственно подаваемых нестабильных данных), валидацию входных параметров API. Интеграционные тесты проверяют корректность работы pipeline-а от загрузки данных до сохранения прогнозов в БД на ограниченном тестовом наборе инструментов. Тестирование запуска полного DAG-а в среде Airflow выполнялось через `airflow dags test`, что позволяет запустить DAG в изолированном режиме без записи в metadata-БД Airflow. Анализ устойчивости pipeline-а проводился через имитацию типовых сбоев (недоступность Yahoo Finance, временный сбой подключения к БД, несходимость GARCH на конкретном окне) — во всех случаях механизмы повторного запуска Airflow и fallback на EWMA в моделирующем модуле обеспечивают корректное завершение pipeline-а с детализированной записью в `etl_log`. Время отклика API на типовых запросах (выгрузка истории за год, получение прогнозов за месяц) измерено и составляет 80–250 миллисекунд, что укладывается в нефункциональное требование о субсекундном отклике.

Сводное сравнение функциональности разработанного сервиса с тремя категориями существующих аналогов представлено в таблице 4.3.

Таблица 4.3 — Сравнение функциональности разработанного сервиса с существующими аналогами.

Критерий	Bloomberg / Refinitiv	TradingView / Investing	Открытые ноутбуки	Разработанный сервис
Стоимость для пользователя	Очень высокая ($\approx \$2k+$ /мес)	Бесплатно / низкая	Бесплатно	Бесплатно
Открытость кода и моделей	Закрыта	Закрыта	Открыта	Открыта
Регулярный обновляемый pipeline	Да	Да	Нет	Да
Хранение истории прогнозов	Да	Частично	Нет	Да
Прогноз волатильности эконометрической моделью	Да	Нет	Да (разово)	Да
Учёт leverage-эффекта (GJR/EGARCH)	Да	Нет	Иногда	Да
Калибровка прогнозов на HAR-признаках	Нет	Нет	Редко	Да
Программный REST API	Да (платный)	Ограниченно	Нет	Да
Интерактивный дашборд	Да	Да	Нет	Да
Визуализация рыночного контекста к паре	Частично	Частично	Нет	Да
Возможность кастомизации модели пользователем	Нет	Нет	Да	Да
Воспроизводимое развёртывание (Docker)	—	—	Нет	Да

Достоинства разработанного решения:

Полнота pipeline. Сервис представляет собой завершённое решение, охватывающее все стадии от сбора данных до визуализации, тогда как большинство открытых аналогов ограничиваются исследовательскими ноутбуками без инфраструктуры регулярного обновления.

Качество модели. Комбинация GJR-GARCH со скошенным t-распределением и Ridge-калибровки на HAR-признаках демонстрирует устойчивое улучшение качества прогноза волатильности на всех 10 парах относительно baseline-а (среднее снижение RMSE на 20%).

Открытость и воспроизводимость. Все компоненты сервиса открыты, упакованы в Docker и развёртываются одной командой, что обеспечивает воспроизводимость для других исследователей и возможность дальнейшего развития сообществом.

Расширяемость. Архитектура с разделением на слои и единым интерфейсом моделей допускает добавление новых пар, признаков и моделей без существенной переработки кода.

Специализированная финансовая метрика. Использование асимметричной RMSE для оценки качества модели отражает специфику финансовых рисков и отличает работу от стандартных ML-подходов.

Контекст в дашборде. Визуализация созависимых инструментов рядом с целевой парой даёт пользователю экономическую интуицию о причинах текущего состояния волатильности.

Ограничения и недостатки разработанного решения:

Качество исходных данных. Использование `yfinance` накладывает ограничения по точности и полноте данных по сравнению с профессиональными источниками (Bloomberg, Refinitiv); периодически в данных встречаются артефакты, требующие постпроцессинга.

Дневной горизонт. Текущая реализация работает только на дневных данных. Расширение на внутрисдневные горизонты потребует существенного изменения инфраструктуры (увеличение нагрузки на БД, переход к streaming-обработке) и не реализовано в рамках MVP.

Ограниченный набор моделей. В работе сравниваются две модели EWMA и GJR-GARCH с калибровкой. Расширение на ML/DL-модели (LSTM, бустинги) и сравнение с ними оставлено как направление дальнейшей работы.

Отсутствие персонализации. Сервис в текущей реализации не поддерживает учётные записи пользователей, индивидуальные настройки или сохранённые портфели — это сделано сознательно для упрощения MVP.

Зависимость от единственного внешнего источника. При длительной недоступности Yahoo Finance pipeline не сможет получать новые данные. В качестве отказоустойчивого расширения возможно подключение нескольких источников с приоритизацией.

Перечисленные ограничения не противоречат концепции MVP: сервис в текущей форме демонстрирует жизнеспособность предложенной архитектуры и качество реализованных моделей, при этом оставляя ясные направления развития.

В четвёртой главе описана реализация MVP-сервиса в виде мультиконтейнерного Docker-приложения, развёрнутого на сервере с публичным доменом. Описана структура репозитория, объёмные характеристики разработки (порядка 2500 строк Python-кода, 8 эндпоинтов API, 9 задач в основном DAG-е, 7 таблиц БД, 6 контейнеров) и порядок запуска сервиса. Рассмотрены два сценария взаимодействия пользователя с сервисом — через интерактивный Streamlit-дашборд с фильтрацией по парам и отображением рыночного

контекста, и через программный REST API с автоматически генерируемой Swagger-документацией. Проведено многоуровневое тестирование сервиса, включающее модульные и интеграционные тесты, а также имитацию сбоев. Сводное сравнение с тремя категориями существующих аналогов (коммерческие платформы, розничные сервисы, открытые ноутбуки) показало, что разработанное решение занимает нишу открытого воспроизводимого сервиса с качеством статистического моделирования, сопоставимым с эконометрическими модулями коммерческих платформ, но отличающимся открытостью и расширяемостью.

Заключение

В рамках выпускной квалификационной работы разработан конвейер данных по мониторингу валютных пар, реализующий полный цикл от сбора исторических котировок до предоставления пользователю прогнозов волатильности через интерактивный дашборд и программный REST API. Все поставленные во введении задачи решены.

Основные результаты работы. Проведён обзор моделей прогнозирования волатильности (EWMA, GARCH-семейство, HAR, ML/DL-подходы) и существующих сервисов мониторинга финансовых рынков, обоснован выбор GJR-GARCH со скошенным t -распределением и онлайн-калибровкой на HAR-признаках в качестве продвинутой модели. Сформулированы функциональные и нефункциональные требования к сервису, обоснован набор из пяти метрик качества, включая специализированную асимметричную RMSE, отражающую финансовую асимметрию рисков недооценки и переоценки волатильности.

Спроектирована архитектура сервиса, включающая шесть функциональных слоёв (источник данных, сбор, хранение, обработка, оркестрация, представление). Разработана нормализованная схема базы данных PostgreSQL из семи таблиц, обеспечивающая целостность через внешние ключи, производительность через специализированные индексы и аудируемость через `model_registry` и `etl_log`. Реализованы REST API на FastAPI с восемью эндпоинтами, интерактивный дашборд на Streamlit с разделением на блоки цены, индекса волатильности и рыночного контекста, и единый DAG Apache Airflow, обеспечивающий ежедневный запуск pipeline-а по расписанию.

Выгружен и обработан датасет из 10 валютных пар и 19 сопутствующих инструментов общим объёмом порядка 200 тыс. строк котировок за период с 2000 года. Реализованы базовая модель EWMA и продвинутая модель GJR-GARCH с Ridge-калибровкой по HAR-признакам. Сравнительный анализ на walk-forward тестовой выборке по пяти метрикам (MSE, RMSE, MAE, R^2 , асимметричная RMSE) показал устойчивое превосходство продвинутой модели над базовой на всех 10 валютных парах со средним снижением RMSE на 20%, MSE на 35% и асимметричной RMSE на 21%. Декомпозиция показала, что примерно две трети улучшения обеспечивается переходом к GJR-GARCH, а оставшаяся треть — Ridge-калибровкой.

Сервис реализован в виде мультиконтейнерного Docker-приложения и развёрнут на сервере с публичным доменом и SSL-сертификатами, что обеспечивает его доступность через интернет. Сравнение функциональности с существующими аналогами (коммерческие платформы Bloomberg/Refinitiv, розничные сервисы TradingView/Investing, открытые ноутбуки) показало, что разработанное решение занимает нишу открытого воспроизводимого сервиса с качеством статистического моделирования, сопоставимым с эконометрическими модулями

коммерческих платформ, но отличающимся полной открытостью кода и моделей, расширяемостью и возможностью кастомизации.

Новизна и практическая значимость работы заключаются в комбинации статистической модели GJR-GARCH со скошенным t -распределением и онлайн-калибровки через ridge-регрессию по HAR-признакам, в специализированной асимметричной метрике качества для финансовых задач, и в реализации полноценного открытого data-pipeline-a от сбора данных до интерактивной визуализации, отсутствующего в существующих открытых аналогах. Сервис может использоваться для исследовательских задач (бэктестинг новых моделей волатильности на унифицированной инфраструктуре), образовательных целей (демонстрация полного жизненного цикла финансового data-сервиса), а также как прототип для построения внутренних инструментов мониторинга в финансовых организациях.

Перспективы дальнейшего развития сервиса включают несколько направлений. Во-первых, расширение набора моделей — включение GARCH-X-расширений с внешними регрессорами (волатильность рыночного контекста), нейросетевых моделей (LSTM, Temporal Fusion Transformer) и сравнение с предложенной комбинированной моделью. Во-вторых, переход к внутридневным данным с соответствующей переработкой инфраструктуры (TimescaleDB, streaming-обработка). В-третьих, добавление пользовательских аккаунтов с возможностью сохранения наблюдательных списков и настройки оповещений о превышении порогов индекса волатильности. В-четвёртых, разработка модуля автоматического переобучения моделей с мониторингом drift-a и использованием метрик из `model_registry`. В-пятых, интеграция с альтернативными источниками данных (Alpha Vantage, Polygon.io) для отказоустойчивости. Реализация части этих направлений возможна силами одного разработчика на горизонте нескольких месяцев и не требует пересмотра базовой архитектуры сервиса.

Источники

1. Bank for International Settlements. Triennial Central Bank Survey of Foreign Exchange and Over-the-Counter (OTC) Derivatives Markets in 2022. — Basel: BIS, 2022. URL: <https://www.bis.org/statistics/rpfx22.htm> (дата обр. 27.04.2026).
2. J.P. Morgan / Reuters. RiskMetrics — Technical Document. 4th Edition. — New York: Morgan Guaranty Trust Company, 1996.
3. Engle R. F. Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation // *Econometrica*. — 1982. — Vol. 50, № 4. — P. 987–1007.
4. Bollerslev T. Generalized Autoregressive Conditional Heteroskedasticity // *Journal of Econometrics*. — 1986. — Vol. 31, № 3. — P. 307–327.
5. Black F. Studies of Stock Price Volatility Changes // *Proceedings of the 1976 Meetings of the American Statistical Association, Business and Economic Statistics Section*. — 1976. — P. 177–181.
6. Glosten L. R., Jagannathan R., Runkle D. E. On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks // *The Journal of Finance*. — 1993. — Vol. 48, № 5. — P. 1779–1801.
7. Nelson D. B. Conditional Heteroskedasticity in Asset Returns: A New Approach // *Econometrica*. — 1991. — Vol. 59, № 2. — P. 347–370.
8. Hansen B. E. Autoregressive Conditional Density Estimation // *International Economic Review*. — 1994. — Vol. 35, № 3. — P. 705–730.
9. Corsi F. A Simple Approximate Long-Memory Model of Realized Volatility // *Journal of Financial Econometrics*. — 2009. — Vol. 7, № 2. — P. 174–196.
10. Kim H. Y., Won C. H. Forecasting the Volatility of Stock Price Index: A Hybrid Model Integrating LSTM with Multiple GARCH-Type Models // *Expert Systems with Applications*. — 2018. — Vol. 103. — P. 25–37.
11. Sheppard K. arch — ARCH for Python. URL: <https://arch.readthedocs.io/> (дата обр. 27.04.2026).
12. Aroussi R. yfinance — Yahoo Finance market data downloader. URL: <https://pypi.org/project/yfinance/> (дата обр. 27.04.2026).
13. Apache Airflow Documentation. URL: <https://airflow.apache.org/docs/> (дата обр. 27.04.2026).
14. FastAPI Documentation. URL: <https://fastapi.tiangolo.com/> (дата обр. 27.04.2026).
15. Streamlit Documentation. URL: <https://docs.streamlit.io/> (дата обр. 27.04.2026).
16. Tsay R. S. Analysis of Financial Time Series. — 3rd ed. — Hoboken: Wiley, 2010. — 720 p.

17. Christoffersen P. F. Elements of Financial Risk Management. — 2nd ed. — San Diego: Academic Press, 2012. — 348 p.
18. Andersen T. G., Bollerslev T., Christoffersen P. F., Diebold F. X. Volatility and Correlation Forecasting // Handbook of Economic Forecasting. — Amsterdam: Elsevier, 2006. — Vol. 1. — P. 777–878.
19. Patton A. J. Volatility Forecast Comparison Using Imperfect Volatility Proxies // Journal of Econometrics. — 2011. — Vol. 160, № 1. — P. 246–256.
20. PostgreSQL Documentation. URL: <https://www.postgresql.org/docs/> (дата обр. 27.04.2026).